

Министерство науки и высшего образования Российской Федерации
Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт

Работа допущена к защите
Руководитель образовательной программы
«Прикладная математика и информатика»

_____ К.Н. Козлов
«___» _____ 2026 г.

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
РАБОТА БАКАЛАВРА
СТАТИСТИЧЕСКОЕ МОДЕЛИРОВАНИЕ И ПРОГНОЗИРОВАНИЕ В
ФУТБОЛЕ НА ОСНОВЕ ДАННЫХ МАТЧЕВОЙ СТАТИСТИКИ И
МАШИННОГО ОБУЧЕНИЯ

по направлению подготовки 01.03.02 Прикладная математика и информатика
Направленность (профиль) 01.03.02_02 Системное программирование

Выполнил
студент гр. 5030102/20202

С.Е. Тишковец

Руководитель
доцент ВШПМиВФ, к.ф.-м.н.

С.В. Крашенинников

Консультант ВКР

Д.Ю. Иванов

Санкт-Петербург
2026

Министерство науки и высшего образования Российской Федерации
Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт

УТВЕРЖДАЮ

Руководитель ОП

К.Н. Козлов

«__» _____ 2026г.

ЗАДАНИЕ

на выполнение выпускной квалификационной работы

студенту Тишковцу Сергею Евгеньевичу, гр. 5030102/20202

1. Тема работы: Статистическое моделирование и прогнозирование в футболе на основе данных матчевой статистики и машинного обучения
2. Срок сдачи студентом законченной работы: 31.05.2026
3. Исходные данные по работе:
 - Открытые наборы данных матчевой статистики и характеристик игроков из источников: Платформа Kaggle (архивные данные по европейским лигам за 2014–2023 гг., детальные протоколы матчей);
 - SoFIFA.com (атрибуты игроков: скорость, дриблинг, физические показатели и др.); Transfermarkt API (динамика рыночной стоимости игроков, сроки контрактов);
 - FBref.com (продвинутые метрики: ожидаемые голы xG, точность передач под давлением).
 - Объём выборки: более 16 000 матчей и характеристики более 30 000 уникальных игроков.
4. Содержание работы (перечень подлежащих разработке вопросов):
 - Сбор, очистка и объединение данных из открытых источников;
 - Разведочный анализ данных (EDA) – исследование распределений, корреляций, проверка статистических гипотез;
 - Статистическое моделирование исходов матчей на основе распределения Пуассона;
 - Применение методов машинного обучения (классификация исходов матчей, регрессия для прогнозирования рыночной стоимости игроков, кластеризация игроков для профилирования футболистов по стилю игры);
 - Глубокое обучение для временных рядов – прогнозирование динамики формы и стоимости игроков;
 - Сравнительный анализ точности и интерпретируемости построенных моделей.
5. Перечень графического материала (с указанием обязательных чертежей): не предусмотрено
6. Перечень используемых информационных технологий, в том числе программное обеспечение, облачные сервисы, базы данных и прочие сквозные цифровые технологии (при наличии):

- Язык программирования Python;
- Библиотеки: pandas, NumPy, SciPy, scikit-learn, XGBoost, CatBoost, TensorFlow;
- Источники данных: Kaggle, Transfermarkt API, SoFIFA, FBref.

7. Консультанты по работе: Д.Ю. Иванов

8. Дата выдачи задания: 10.12.2025

Руководитель ВКР



(подпись)

С.В. Крашенинников

Задание принял к исполнению: 10.12.2025

Студент



С.Е. Тишковец

(подпись)

РЕФЕРАТ

На 41 с., 8 рис., 17 табл.

Ключевые слова: ФУТБОЛ, СТАТИСТИЧЕСКОЕ МОДЕЛИРОВАНИЕ, МАШИННОЕ ОБУЧЕНИЕ, ПРОГНОЗИРОВАНИЕ, СПОРТИВНАЯ АНАЛИТИКА, РЫНОЧНАЯ СТОИМОСТЬ.

Тема выпускной квалификационной работы: «Статистическое моделирование и прогнозирование в футболе на основе данных матчевой статистики и машинного обучения».

Настоящая работа посвящена разработке и сравнению эффективности статистических моделей, алгоритмов машинного обучения и нейронных сетей для решения задач прогнозирования исходов матчей и оценки стоимости игроков.

Задачи, которые решались в ходе исследования:

1. Сбор и интеграция данных по «Большой пятёрке» европейских лиг за период 2014–2023 гг.
2. Математическая валидация применимости распределения Пуассона для моделирования голов.
3. Разработка статистических и ML-моделей для классификации исходов и регрессии стоимости.
4. Проведение сегментации футболистов по стилю игры методами кластеризации.
5. Проектирование рекуррентной нейронной сети LSTM для анализа динамики временных рядов.
6. Сравнительный анализ точности и интерпретируемости всех построенных моделей.

Работа проведена на основе открытых наборов данных Kaggle, Transfermarkt и SoFIFA, где собиралась значительная часть фактического материала: матчевая статистика и исторические транзакции.

Были проведены расчеты, демонстрирующие превосходство алгоритмических подходов над линейными. Анализ проводился методами математического моделирования (модификация Диксона-Коулза) и интеллектуального анализа данных (градиентный бустинг).

В результате был проанализирован комплекс данных из 16 000 матчей. Модели на базе CatBoost показали точность прогноза исходов 76% и коэффициент детерминации стоимости $R^2 = 0,827$. Нейросеть MLP достигла точности 75,2%, подтвердив конкурентоспособность DL-методов.

Применение LSTM позволило прогнозировать тренды стоимости с MAPE = 17,8% на стабильных данных.

Для достижения указанных результатов использованы современные информационные технологии: язык программирования Python (библиотеки pandas, scikit-learn, CatBoost, TensorFlow/Keras).

ABSTRACT

On 41 pages, 8 figures, 17 tables.

Keywords: FOOTBALL, STATISTICAL MODELING, MACHINE LEARNING, PREDICTIVE ANALYTICS, MARKET VALUE.

The subject of the graduate qualification work is «Statistical Modeling and Forecasting in Football Based on Match Statistics Data and Machine Learning».

This work is devoted to the development and comparison of statistical, machine learning (ML), and deep learning (DL) models for predicting match outcomes and estimating players' market values.

The research set the following goals:

1. Collection and integration of the "Top-5" European leagues data (2014–2023).
2. Validation of the Poisson distribution for modeling goals scored.
3. Development of statistical and ML models for outcome classification and value regression.
4. Player segmentation by playing style using clustering methods.
5. Designing an LSTM recurrent neural network for time series analysis.
6. Comparative analysis of the accuracy and interpretability of all constructed models.

The work was performed based on open datasets from Kaggle, Transfermarkt, and SoFIFA, covering match statistics and historical transfer transactions.

Calculations were conducted to demonstrate the superiority of algorithmic approaches over linear ones. The analysis was performed using mathematical modeling (Dixon-Coles modification) and data mining techniques (gradient boosting).

As a result, a dataset of 16,000 matches was analyzed. CatBoost models showed an outcome prediction accuracy of 76% and a value determination coefficient of $R^2 = 0.827$. The MLP neural network achieved an accuracy of 75.2%. The application of LSTM made it possible to forecast value trends with a MAPE of 17.8% on stable time series.

To achieve these results, modern information technologies were used: Python (pandas, scikit-learn, CatBoost, TensorFlow/Keras).

СПИСОК УСЛОВНЫХ ОБОЗНАЧЕНИЙ И СОКРАЩЕНИЙ

Метрики и показатели

1. **xG (Expected Goals)** — ожидаемые голы; метрика вероятности взятия ворот.
2. **RMSE (Root Mean Square Error)** — корень из среднеквадратичной ошибки.
3. **MAE (Mean Absolute Error)** — средняя абсолютная ошибка.
4. **MAPE (Mean Absolute Percentage Error)** — средняя абсолютная ошибка в процентах.
5. **Log-Loss** — логистическая функция потерь.
6. **ROC-AUC** — площадь под кривой ошибок; метрика качества классификации.
7. **R^2** — коэффициент детерминации.
8. **IQR (Interquartile Range)** — межквартильный размах.

Алгоритмы и архитектуры

9. **XGBoost, CatBoost** — алгоритмы машинного обучения на основе градиентного бустинга.
10. **Random Forest** — алгоритм на основе ансамбля деревьев решений.
11. **MLP (Multilayer Perceptron)** — многослойный перцептрон.
12. **LSTM (Long Short-Term Memory)** — рекуррентная нейронная сеть с долгой краткосрочной памятью.
13. **ARIMA** — интегрированная модель авторегрессии — скользящего среднего.
14. **K-Means** — алгоритм кластеризации методом K-средних.
15. **DBSCAN** — алгоритм плотностной кластеризации.
16. **OLS (Ordinary Least Squares)** — метод наименьших квадратов.

Математические символы и статистика

17. **λ** — параметр интенсивности распределения Пуассона.
18. **ρ** — коэффициент корреляции Пирсона; параметр зависимости в модели Диксона-Коулза.
19. **τ** — корректирующая функция вероятностей в модели Диксона-Коулза.
20. **α** — уровень статистической значимости; рейтинг атакующей силы команды.
21. **β** — рейтинг защитной силы команды.
22. **p-value** — достигаемый уровень значимости в гипотезном тестировании.
23. **MLE (Maximum Likelihood Estimation)** — метод максимального правдоподобия.

- 24. χ^2 — статистический критерий согласия Пирсона.
- 25. **df (degrees of freedom)** — число степеней свободы.
- 26. **CI (Confidence Interval)** — доверительный интервал.

Технологии

- 27. **EDA (Exploratory Data Analysis)** — разведочный анализ данных.
- 28. **API (Application Programming Interface)** — программный интерфейс приложения.
- 29. **ReLU, Softmax** — функции активации слоев нейронной сети.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	11
ГЛАВА 1. ОБЗОР СУЩЕСТВУЮЩЕЙ ЛИТЕРАТУРЫ	12
1.1. Статистические модели в прогнозировании исходов матчей	12
1.2. Машинное обучение в предсказании исходов матчей и стоимости игроков	12
1.3. Глубокое обучение и временные ряды	14
1.4. Анализ ограничений	14
1.5. Постановка задачи выпускной квалификационной работы	15
ГЛАВА 2. ИСТОЧНИКИ И ОПИСАНИЕ ДАННЫХ	16
2.1. Перечень используемых ресурсов	16
2.2. Предобработка данных	16
ГЛАВА 3. РАЗВЕДОЧНЫЙ И СТАТИСТИЧЕСКИЙ АНАЛИЗ ДАННЫХ (EDA)	17
3.1. Анализ базовых распределений и описательная статистика лиг	17
3.2. Проверка статистических предположений Пуассона для количества голов	19
3.3. Корреляционный анализ игровых метрик и экономических показателей	20
3.4. Построение доверительных интервалов	21
3.5. Визуализация данных и выявление паттернов	22
3.6. Анализ временных рядов и динамика формы	23
3.7. Выводы по главе 3	24
ГЛАВА 4. СТАТИСТИЧЕСКОЕ МОДЕЛИРОВАНИЕ ИСХОДОВ МАТЧЕЙ ...	25
4.1. Модель распределения Пуассона для прогнозирования голов	25
4.2. Оценка параметров через метод максимального правдоподобия	25
4.3. Модификация Диксона-Коулза	26
4.5. Симуляция сезона методом Монте-Карло	27
4.6. Выводы по главе 4	27
ГЛАВА 5. ПРИМЕНЕНИЕ МЕТОДОВ МАШИННОГО ОБУЧЕНИЯ	29
5.1. Классификация исходов матчей	29
5.2. Регрессия для прогнозирования трансферной стоимости игроков	31

5.3. Выводы по главе 5	32
ГЛАВА 6. КЛАСТЕРИЗАЦИЯ И СЕГМЕНТАЦИЯ ФУТБОЛИСТОВ ПО СТИЛЮ ИГРЫ	33
6.1. Методология и подготовка данных	33
6.2. Определение оптимального количества кластеров.....	33
6.3. Сравнение алгоритмов кластеризации	34
6.4. Интерпретация кластеров	34
6.5. Выводы по главе 6	35
ГЛАВА 7. ВРЕМЕННЫЕ РЯДЫ И НЕЙРОСЕТЕВЫЕ МОДЕЛИ.....	36
7.1. Классификация исходов матчей с помощью MLP	36
7.2. Анализ временных рядов	37
7.3. Сравнительный анализ точности прогнозов.....	37
7.4. Выводы по главе 7	38
ЗАКЛЮЧЕНИЕ	40
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	42

ВВЕДЕНИЕ

Постановка проблемы

Современная футбольная индустрия характеризуется беспрецедентным уровнем цифровизации: объем собираемых данных о матчах и игроках удваивается ежегодно. Однако наличие больших данных само по себе не гарантирует качества принимаемых решений. Ключевая проблема заключается в глубоком методологическом разрыве между двумя подходами:

1. Простая статистика, которая обладает высокой интерпретируемостью, но довольно низкой прогностической мощностью из-за субъективности и игнорирования нелинейных зависимостей.
2. Сложные алгоритмы машинного обучения, которые показывают высокую точность, но часто воспринимаются как черный ящик, что ограничивает их доверие со стороны любителей футбола.

Необходимость поиска баланса между точностью и интерпретируемостью в условиях высокой стохастичности футбола определяет научную проблему настоящей работы.

Актуальность темы

Актуальность исследования обусловлена критическим ростом финансовых рисков в мировом футболе. В 2024–2025 годах рынок трансферов столкнулся с высокой инфляцией, где ошибка в оценке рыночной стоимости игрока на 10–15% может стоить клубу десятки миллионов евро. В этих условиях разработка математически обоснованных инструментов объективной оценки становится не просто вспомогательным, а необходимым элементом выживания в конкурентной среде. Применение продвинутой аналитики позволяет клубам с ограниченными ресурсами конкурировать с грандами за счет выявления недооцененных талантов, что подтверждает прикладную значимость выбранной темы.

Цель и мотивация

Целью работы является разработка и проведение сравнительного анализа эффективности статистических моделей и моделей машинного обучения для решения ключевых задач футбольной аналитики: прогнозирования исходов матчей и оценки рыночной стоимости игроков.

Мотивация кроется в практической ценности: данные помогают принимать спортивные и коммерческие решения. В итоге, исследование способствует переходу к подходу, основанному на доказательствах, в футболе, где объективные модели дополняют человеческий опыт.

ГЛАВА 1. ОБЗОР СУЩЕСТВУЮЩЕЙ ЛИТЕРАТУРЫ

1.1. Статистические модели в прогнозировании исходов матчей

Футбольная аналитика представляет собой активно развивающуюся область исследования. Существуют многочисленные публикации по прогнозированию результатов матчей и оценке игроков. Одним из классических подходов к предсказанию футбольных матчей является использование пуассоновских моделей. В работе [1] на данных Английской Премьер-лиги за 10 сезонов с помощью регрессии Пуассона оценены атакующие и защитные рейтинги команд; точность предсказания победителя составила около 55%. Авторы показали, что модель хорошо описывает независимые события, но не учитывает корреляции между атаками команд и временные изменения формы. В отечественной литературе статистические аспекты прогнозирования спортивных событий также получили развитие. В статье [2] проведён анализ вероятностей спортивных исходов с применением распределения Пуассона и других статистических методов, рассмотрены вопросы построения доверительных интервалов и проверки гипотез о различиях между лигами.

Байесовские расширения пуассоновских моделей позволяют улучшить гибкость и точность прогнозов. В ряде зарубежных исследований (см. обзор [2]) применяются гамма-приоры для учёта сверхдисперсии, когда наблюдаемая дисперсия превышает теоретическую. Это даёт прирост точности на 5–7% по сравнению с базовой моделью, сохраняя интерпретируемость параметров. Современные исследования продолжают совершенствовать пуассоновский подход: в исследовании [3] на обширном наборе данных европейских лиг показано, что пуассоновская регрессия с корректным учётом силы соперников и калибровкой вероятностей обеспечивает высокую точность прогнозирования исходов матчей, сравнимую с некоторыми методами машинного обучения. Указанные работы подтверждают практическую ценность статистических моделей для оценки вероятностей исходов и позиций команд в таблице на основе забитых и пропущенных мячей.

1.2. Машинное обучение в предсказании исходов матчей и стоимости игроков

Переход к машинному обучению позволил повысить точность прогнозов за счёт учёта нелинейных зависимостей и большего объёма признаков. В выпускной квалификационной работе [4] на данных европейских топ-лиг сравниваются алгоритмы Random Forest, градиентного бустинга (XGBoost, CatBoost) и логистической регрессии; наилучший

результат по метрикам Accuracy и ROC-AUC достигается при использовании ансамблевых методов, а важнейшими признаками оказываются скользящие средние голов и ожидаемые голы (xG). Аналогичные выводы получены в [5], где автор акцентирует внимание на подборе гиперпараметров и борьбе с переобучением на временных рядах. В тезисах [6] показана эффективность применения методов ML для прогнозирования результатов футбольных матчей на данных российских и международных турниров, с точностью до 72% для некоторых конфигураций.

Сравнительный анализ нескольких методов машинного обучения, включая нейросетевые подходы и ансамбли, проведён в статье [7]: авторы демонстрируют, что градиентный бустинг и глубокие нейронные сети могут улучшать прогноз спортивных событий, однако требуют тщательной предобработки данных и настройки. Выпускная работа [8] также посвящена прогнозированию исходов спортивных событий с помощью ML и подтверждает целесообразность использования современных алгоритмов.

В контексте оценки рыночной стоимости игроков машинное обучение играет всё более важную роль. В статье [9] на основе данных о характеристиках футболистов построены регрессионные модели, включая линейную регрессию, деревья решений и градиентный бустинг. Показано, что CatBoost и XGBoost обеспечивают коэффициент детерминации R^2 выше 0.8, а наибольший вклад вносят общий рейтинг, потенциал и навыки дриблинга. Обзор [10] рассматривает применение искусственного интеллекта в трансферном рынке и автоматизации оценки стоимости игроков, выделяя преимущества и ограничения таких моделей: высокая точность при наличии качественных данных, но необходимость аккуратного учёта рыночных факторов и временных изменений. Более поздние работы предлагают гибридные подходы для оценки стоимости. Так, в работе [11] комбинация бэггинга и методов машинного обучения демонстрирует превосходство над традиционными регрессионными моделями при прогнозировании трансферной стоимости. Исследование [12] представляет новый метод машинного обучения, учитывающий не только индивидуальные характеристики игрока, но и динамику рынка, что позволяет повысить точность оценки стоимости в условиях волатильности трансферов.

Задача кластеризации футболистов для выявления скрытых ролей и поиска аналогов также решается методами ML. В работе [8] алгоритмы K-средних и иерархической кластеризации применялись к игровым характеристикам игроков, что позволило сегментировать их на атакующих и оборонительных, а также находить близкие замены в скаутинговых системах. Подобные подходы демонстрируют перспективность обучения без учителя в футбольной аналитике.

1.3. Глубокое обучение и временные ряды

Использование глубокого обучения в футбольной аналитике пока носит ограниченный характер, однако имеющиеся результаты обнадеживают. В работе [13] для предсказания результатов футбольных матчей применялась многослойная нейронная сеть; авторы отметили, что нейросетевая модель способна улавливать сложные нелинейные зависимости и превосходит классические статистические методы при достаточном объеме обучающих данных. В [7] сравниваются различные архитектуры, включая рекуррентные нейронные сети (LSTM), для анализа временных рядов спортивных событий. Показано, что LSTM-сети могут эффективно прогнозировать динамику показателей команды или стоимости игрока, однако их качество сильно зависит от длины доступной истории и качества предобработки. Дальнейшим развитием глубоких архитектур стало применение гибридных CNN-BiLSTM моделей: в [14] такая сеть, учитывающая совместимость игроков и изменения в составе, использована для прогноза вероятности победы, показав высокую точность на реальных данных. Фреймворк [15] на основе глубокого обучения объединяет предсказание исхода матча с количественной оценкой эффективности команды, что открывает новые возможности для аналитики.

Классические модели временных рядов (ARIMA, экспоненциальное сглаживание) по-прежнему используются как базовые бенчмарки. Ограничением моделей глубокого обучения остаётся склонность к переобучению при малых выборках и трудности в интерпретации результатов. В целом, применение рекуррентных нейронных сетей в футбольной аналитике требует дальнейшего изучения, но представляет собой перспективное направление для прогнозирования стоимости и формы игроков.

1.4. Анализ ограничений

Проведенный обзор литературы выявил ряд существенных ограничений классических статистических методов, которые предопределяют необходимость интеграции машинного обучения в исследование. Во-первых, базовое распределение Пуассона предполагает, что голы хозяев и гостей — это независимые события. Однако в реальности тактические перестроения во время матча создают зависимость, которую Пуассон игнорирует, занижая вероятность ничьих. Во-вторых, хоть и на уровне лиги распределение голов хорошо аппроксимируется Пуассоном, на уровне отдельного клуба в рамках одного сезона случайный шум слишком велик, что делает модель нестабильной. В-третьих, статистические модели оперируют только историей голов, в то время как ML-алгоритмы способны учитывать контекстные признаки.

Таким образом, в работе обосновывается переход от чистой статистики к гибридной схеме, где статистические рейтинги силы команд выступают в качестве базовых признаков для более сложных ML-алгоритмов.

1.5. Постановка задачи выпускной квалификационной работы

На основе итогов литературного обзора формулируется следующее задание на разработку методологии и проведение экспериментов в рамках работы:

- Требования к данным: обеспечить охват «Большой пятерки» европейских лиг за период 2014–2023 гг., реализовать процедуру очистки и нормализации данных.
- Требования к статистическому моделированию: рассчитать атакующие и защитные рейтинги команд, внедрить модификацию Диксона-Коулза для коррекции вероятностей низких счетов.
- Требования к машинному обучению: реализовать классификатор исходов с использованием градиентного бустинга, построить регрессионную модель оценки стоимости игроков, для временных рядов протестировать архитектуру LSTM в сравнении с классической ARIMA.
- Критерии сравнения моделей: использовать метрики Log-Loss и Ассигасу для матчей, RMSE и MAPE для стоимости, проанализировать важность признаков и визуализировать профили игроков через радарные диаграммы.

ГЛАВА 2. ИСТОЧНИКИ И ОПИСАНИЕ ДАННЫХ

2.1. Перечень используемых ресурсов

Для формирования информационной базы исследования использованы статические выгрузки данных из открытых репозиторий и агрегаторов. Основные источники:

- **Платформа Kaggle:** выгрузка архивов европейских лиг за 2014–2023 гг., содержащая протоколы более 16 000 матчей.
- **Агрегаторы Transfermarkt и SoFIFA:** CSV-файлы, содержащие исторические данные о рыночной стоимости и атрибутах игроков.
- **FBref.com:** данные по продвинутой статистике, интегрированные в общую выборку на этапе предобработки.

Исследование сфокусировано на «Большой пятерке» европейских лиг, так как для них доступен наиболее полный набор продвинутых метрик: Английская Премьер-лига (EPL), Испанская Ла Лига (La Liga), Немецкая Бундеслига (Bundesliga), Итальянская Серия А (Serie A), Французская Лига 1 (Ligue 1).

2.2. Предобработка данных

Предобработка проводилась в Python с использованием библиотек pandas, NumPy и SciPy для обеспечения качества данных перед моделированием. Основные шаги:

1. **Очистка данных:** пропуски в количественных метриках импутировались медианой, для категориальных признаков пустые значения заполнялись модой. Для фильтрации невалидных значений трансферной стоимости применен метод межквартильного размаха.
2. **Нормализация и масштабирование:** к атрибутам игроков применена Min-Max нормализация в диапазоне $[0,1]$, к временным рядам — стандартизация z-score. Это обеспечило совместимость данных из разных источников.
3. **Формирование признаков:** для повышения предиктивной способности моделей спроектированы такие признаки, как лаги (предыдущие 5 матчей), скользящее среднее для xG и набранных очков, разница рейтингов команд и индекс качества состава.

Данные разделены на обучающую (80%, 2014–2021) и тестовую (20%, 2022–2023) выборки.

ГЛАВА 3. РАЗВЕДОЧНЫЙ И СТАТИСТИЧЕСКИЙ АНАЛИЗ ДАННЫХ (EDA)

Разведочный анализ данных представляет собой критически важный этап в цикле статистического моделирования и машинного обучения. Основная задача EDA заключается не только в визуализации данных, но и в глубоком понимании структуры выборки, выявлении скрытых закономерностей, проверке статистических гипотез и валидации теоретических предположений, на которых базируются классические модели спортивного прогнозирования.

Футбольные данные по своей природе характеризуются высокой зашумленностью, наличием выбросов и сложными нелинейными зависимостями между игровыми показателями и итоговым результатом. Систематический подход к анализу, основанный на принципах математической статистики, позволяет отделить сигнал от шума и сформировать репрезентативный набор признаков для алгоритмов классификации и регрессии.

3.1. Анализ базовых распределений и описательная статистика лиг

Первым этапом EDA является изучение распределений ключевых метрик на уровне команд и игроков. Для исследования была сформирована выборка из более чем 16 тыс. матчей пяти ведущих европейских лиг за период 2014–2023 годов. Анализ описательных статистик позволяет сформировать профиль каждой лиги и выявить системные различия в их игровых стилях.

Распределение результативности и фактор домашнего поля

Количество голов в футболе является дискретной величиной с ограниченным диапазоном значений, что накладывает специфические требования к анализу. На протяжении десятилетнего периода наблюдения средняя результативность в европейских топ-лигах демонстрирует высокую степень стабильности, однако между чемпионатами сохраняются устойчивые различия.

Лига	Матчей в выборке	Среднее кол-во голов дома	Среднее кол-во голов на выезде	Общая результативность	Процент ничьих
Bundesliga	2754	1.684	1.311	2.995	24.7
EPL	3420	1.520	1.219	2.739	23.5
La liga	3420	1.500	1.125	2.625	25.8
Ligue 1	3318	1.484	1.165	2.649	25.8
Serie A	3420	1.527	1.263	2.789	25.3

Таблица 3.1. Описательная статистика забитых голов по лигам

Данные таблицы показывают, что наибольшая результативность наблюдается в немецкой Бундеслиге, за ней следует итальянская Серия А. Самая низкая результативность зафиксирована в испанской Ла Лиге и французской Лиге 1. Фактор домашнего поля выражен во всех лигах: хозяева забивают в среднем на 20–25 % больше, чем гости.

Распределение ожидаемых голов (xG) и их качество

Метрика xG предоставляет более глубокое понимание результативности, оценивая вероятность каждого удара стать голом на основе множества факторов. В отличие от дискретных голов, xG является квазинепрерывной величиной, агрегируемой на уровне матча.

Лига	Матчей в выборке	Средний xG дома	Средний xG на выезде	Общий xG за матч
Bundesliga	2754	1.623	1.287	2.911
EPL	3420	1.516	1.214	2.730
La liga	3420	1.522	1.132	2.654
Ligue 1	3318	1.448	1.137	2.585
Serie A	3420	1.506	1.237	2.743

Таблица 3.2. Распределение ожидаемых голов по лигам

Анализ ожидаемых голов подтверждает правостороннюю асимметрию распределения. В среднем команды генерируют от 2,585 до 2,911 xG за матч. Наиболее высокие значения xG как дома, так и на выезде наблюдаются в Бундеслиге. Сравнение xG и реальных голов показывает, что в долгосрочной перспективе эти показатели стремятся к равенству.

3.2. Проверка статистических предположений Пуассона для количества голов

Центральным элементом статистического моделирования исходов футбольных матчей является предположение о том, что голы в течение 90 минут распределены согласно закону Пуассона. Это предположение базируется на том, что взятие ворот является редким событием, а время между голами распределено экспоненциально.

Теоретические основы и параметры модели

Для применения распределения Пуассона необходимо определить параметр λ , который в футболе соответствует ожидаемому количеству голов команды в матче. В главе 4 этот параметр будет рассчитываться через силу атаки команды i и силу защиты команды j с учетом среднего показателя лиги.

В рамках EDA мы проверяем, насколько фактические частоты голов в исторической выборке соответствуют теоретическим вероятностям $P(k; \lambda)$

Проверка согласия с помощью критерия Хи-квадрат Пирсона

Для проверки нулевой гипотезы H_0 : «Эмпирическое распределение голов соответствует распределению Пуассона» используется статистика χ^2 . Расчет производится по формуле:

$$\chi^2 = \sum_{i=1}^k \frac{(n_i - np_i)^2}{np_i}$$

где n_i — наблюдаемое количество матчей с i голами, np_i — ожидаемое количество согласно модели Пуассона.

Рассмотрим результаты теста для английской Премьер-лиги

Кол-во голов	Фактических матчей	Ожидаемых матчей	χ^2 вклад
0	815	748.1	5.99
1	1104	1137.0	0.96
2	815	864.1	2.78
3	418	437.8	0.89
4	174	166.3	0.35
5+	94	66.8	4.12

Таблица 3.3. Сравнение фактических и теоретических частот голов в АПЛ

Анализ таблицы показывает высокую степень соответствия. Расчетное значение статистики χ^2 (в среднем 2.9) ниже критического значения (9.49 для 4 степеней свободы при $\alpha = 0.05$). Это позволяет принять нулевую гипотезу H_0 .

Анализ сверхдисперсии и независимости событий

Важным ограничением модели Пуассона является равенство математического ожидания и дисперсии ($E[X] = Var[X] = \lambda$). В реальных данных часто наблюдается сверхдисперсия, когда дисперсия превышает среднее, что может указывать на кластеризацию событий. Кроме того, базовая модель предполагает независимость голов хозяев и гостей, что не всегда верно. Эти нюансы будут учтены в главе 4 при использовании байесовских расширений.

3.3. Корреляционный анализ игровых метрик и экономических показателей

Исследование корреляций позволяет выявить наиболее значимые признаки для предиктивного моделирования и понять внутреннюю механику футбольного успеха. В работе используются коэффициенты корреляции Пирсона (ρ) для линейных зависимостей.

Взаимосвязь голов с остальными командными метриками

Корреляционная матрица командных показателей за сезон выявляет «двигатели» результативности.

Метрика	Корреляция с голами (ρ)
Рейтинг атаки	0.75
Ожидаемые голы (xG)	0.63
Рейтинг полузащиты (владение/передачи)	0.62
xG за последние 4 матча	0.24
Рейтинг атаки за последние 4 матча	0.20

Таблица 3.4. Корреляция командных метрик с количеством забитых голов

Наиболее сильная связь с количеством забитых голов наблюдается у рейтинга атаки и ожидаемых голов xG.

Анализ детерминант рыночной стоимости игроков

Для задачи прогнозирования стоимости критически важен выбор признаков, имеющих высокую связь с целевой переменной.

Признак	Корреляция со стоимостью
Общий рейтинг	0.55
Потенциал	0.51
Дриблинг	0.40
Удары	0.28
Физическая форма	0.22
Скорость	0.18
Оборона	0.15
Возраст	0.03
Рост (см)	0.01

Таблица 3.5. Анализ детерминант рыночной стоимости игроков

Самые сильные положительные корреляции со стоимостью демонстрируют общий рейтинг игрока и потенциал. Среди игровых атрибутов лидируют дриблинг и удары. Возраст и рост практически не влияют на стоимость.

3.4. Построение доверительных интервалов

В прикладной математике простого точечного оценивания недостаточно для принятия решений. Необходимо оценивать неопределенность и точность полученных статистик через доверительные интервалы.

Доверительные интервалы для результативности команд

Доверительный интервал представляет собой диапазон, который с заданной вероятностью покрывает истинное значение популяционного параметра. Для средней результативности лиги при объеме выборки n доверительный интервал рассчитывается как:

$$CI = \bar{X} \pm z_{\alpha/2} \cdot \frac{s}{\sqrt{n}}$$

где $z_{0,05/2} \approx 1,96$.

Для команды «Манчестер Сити» (сезон 2022/23) среднее количество забитых мячей за игру составило 2,84, стандартное отклонение 1,12, количество матчей 38. 95%-й доверительный интервал для истинной силы атаки составляет примерно [2,48; 3,20]. Узкий доверительный интервал

свидетельствует о высокой стабильности результатов «Манчестер Сити». В целом, использование доверительных интервалов позволяет аналитикам оценивать не только наличие эффекта, но и его масштаб, что критически важно для принятия решений о трансферах или смене тактики.

3.5. Визуализация данных и выявление паттернов

Графическое представление данных в EDA позволяет быстро идентифицировать аномалии и подтвердить выводы, полученные аналитическим путем.

Бокс-плоты для анализа выбросов

Диаграммы размаха являются стандартным инструментом для визуализации распределений по категориям. Центральная линия обозначает медиану, границы коробки — 25-й и 75-й процентиля, а усы — диапазон 1,5 IQR.




Рис. 3.1. Распределение xG по командам АПЛ

Анализ xG по командам АПЛ выявляет «Манчестер Сити», «Ливерпуль» и «Арсенал» как явные выбросы, чьи показатели существенно превосходят верхний забор распределения остальной части лиги. Это подтверждает необходимость использования робастных методов оценки.

Радарные диаграммы для профилирования

Радарные диаграммы позволяют одновременно визуализировать множество характеристик игрока. Для профилирования нападающих используются оси: «Общий рейтинг», «Скорость», «Потенциал», «Физическая форма», «Дриблинг», «Удары», «Оборона» и «Точность передач».




Рис. 3.2. Радарные диаграммы профилей игроков

Визуализация показывает, что разные игроки могут иметь схожую рыночную стоимость, но довольно разные игровые профили. Эрлинг Холанд превосходит Килиана Мбаппе по показателям обороны и физической форме, в то время как Мбаппе сильнее в скорости и точности передач. Это наблюдение подготавливает почву для применения алгоритмов кластеризации в Главе 6.

3.6. Анализ временных рядов и динамика формы

Футбольные данные обладают выраженной временной структурой, которую необходимо исследовать в рамках EDA перед применением моделей LSTM или ARIMA.



Рис. 3.3. Динамика средней рыночной стоимости игроков

Временные ряды стоимости игроков из Transfermarkt с годами показывают экспоненциальный рост.

3.7. Выводы по главе 3

Комплексный разведочный и статистический анализ данных позволил сформировать надежный фундамент для последующих этапов исследования. Проведенные процедуры подтвердили соответствие структуры данных теоретическим ожиданиям и выявили ключевые закономерности, определяющие успех в современном футболе. Основные результаты EDA:

- **Математическая валидация:** с помощью критерия Хи-квадрат доказано, что распределение забитых голов в топ-5 европейских лигах не противоречит закону Пуассона.
- **Иерархия факторов:** наиболее сильная связь с количеством забитых голов наблюдается у рейтинга атаки и ожидаемых голов xG.
- **Особенности лиг:** Бундеслига лидирует по средней результативности, Ла Лига и Лига 1 — по проценту ничьих.
- **Экономические паттерны:** самые сильные положительные корреляции со стоимостью демонстрируют общий рейтинг игрока и потенциал, среди игровых атрибутов лидируют дриблинг и удары.
- **Робастность данных:** идентификация выбросов через бокс-плоты и метод IQR позволила сделать выводы для дальнейшей работы с моделью.

Таким образом, результаты Главы 3 подтверждают готовность данных к этапу моделирования и позволяют перейти к непосредственной реализации статистических и машинных алгоритмов прогнозирования.

ГЛАВА 4. СТАТИСТИЧЕСКОЕ МОДЕЛИРОВАНИЕ ИСХОДОВ МАТЧЕЙ

Статистический подход к прогнозированию футбольных результатов основывается на представлении процесса взятия ворот как последовательности случайных событий. В данной главе описывается разработка предиктивной системы, базирующейся на модифицированном распределении Пуассона.

4.1. Модель распределения Пуассона для прогнозирования голов

Для моделирования количества голов, забитых командами, была использована регрессия Пуассона. В базовой модели предполагается, что количество голов хозяев (H) и гостей (A) распределено независимо:

$$P(H = k) = \frac{\lambda_H^k e^{-\lambda_H}}{k!}, \quad P(A = m) = \frac{\lambda_A^m e^{-\lambda_A}}{m!}$$

Интенсивности λ_H и λ_A определяются через экспоненциальную связь с параметрами силы команд:

$$\ln(\lambda_H) = \alpha_{home} + \beta_{away} + \gamma$$

$$\ln(\lambda_A) = \alpha_{away} + \beta_{home}$$

где α — атакующий рейтинг, β — защитный рейтинг, а γ — константа домашнего преимущества.

4.2. Оценка параметров через метод максимального правдоподобия

Оценка параметров α, β, γ проводилась путем минимизации отрицательной функции логарифмического правдоподобия. Алгоритм находит такие значения рейтингов, при которых наблюдаемые в истории результаты матчей становятся наиболее вероятными. Расчетные рейтинги на примере Ла Лиги представлены в таблице.

Команда	Атака (α)	Защита (β)
Real Madrid	0.689	-0.283
Barcelona	0.771	-0.357
Atletico Madrid	0.308	-0.626
Villarreal	0.193	-0.155

Таблица 4.1. Рассчитанные рейтинги силы команд из La Liga

Параметры интерпретируются относительно среднего уровня лиги. Например, значение $\alpha = 0.689$ означает, что команда забивает в $e^{0.689}$ раз больше голов, чем гипотетический средний соперник.

4.3. Модификация Диксона-Коулза

Классическое распределение Пуассона склонно недооценивать вероятность ничейных исходов из-за упрощенного предположения о полной независимости голов команд. Для устранения этого смещения была внедрена модификация Диксона-Коулза.

Суть модификации заключается в введении корректирующей функции $\tau_\rho(x, y)$, которая изменяет совместную вероятность только для четырех специфических счетов (0:0, 0:1, 1:0, 1:1), оставляя остальные значения нетронутыми:

$$P(X = x, Y = y) = \tau_\rho(x, y) \cdot P(X = x) \cdot P(Y = y)$$

Функция $\tau_\rho(x, y)$ определяется следующим образом:

- $\tau_\rho(0,0) = 1 - \lambda_H \lambda_A \rho$
- $\tau_\rho(0,1) = 1 + \lambda_H \rho$
- $\tau_\rho(1,0) = 1 + \lambda_A \rho$
- $\tau_\rho(1,1) = 1 - \rho$
- В остальных случаях $\tau_\rho(x, y) = 1$.

Параметр ρ является коэффициентом зависимости. В ходе программной оптимизации на данных Ла Лиги было получено значение $\rho = -0.0469$. Отрицательное значение параметра указывает на то, что при крайне низкой результативности одной команды вероятность низкого счета другой команды возрастает сильнее, чем предсказывает базовая модель.

4.4. Сравнительный анализ моделей

Эффективность моделей оценивалась на тестовой выборке матчей сезонов 2022–2023 гг.

Модель	Accuracy (1X2)	RPS	Log-Loss
Независимый Пуассон	0.5346	0.2032	0.9913
Модель Диксона-Коулза	0.5363	0.2031	0.9913
Случайный прогноз	0.3333	0.2500	1.0986

Таблица 4.2. Сравнение точности статистических моделей

Точность моделей существенно превышает порог случайного угадывания. Модификация Диксона-Коулза показала стабильный, хотя и небольшой, прирост в точности предсказания исходов.

4.5. Симуляция сезона методом Монте-Карло

На основе построенной модели была проведена симуляция сезона методом Монте-Карло (10 000 итераций), что позволило получить вероятностное распределение итоговых мест.

Команда	Вер. чемпионства	Вер. Топ-4	Ср. ожидаемые очки
Barcelona	82.1	100.0	90.1
Real Madrid	17.8	100.0	83.9
Atletico Madrid	0.1	91.9	70.5
Real Sociedad	0.0	59.3	63.8
Villarreal	0.0	34.7	61.3

Таблица 4.3. Прогноз итоговых позиций (Пример: La Liga 2022/23)

Турнирная таблица по результатам сезона La Liga 2022/23 выглядела следующим образом.

Команда	Очки
Barcelona	88
Real Madrid	78
Atletico Madrid	77
Real Sociedad	71
Villarreal	64

Таблица 4.4. Турнирная таблица (Пример: La Liga 2022/23)

Сравнение таблиц говорит о высокой точности модели для определения лидеров и предсказания итогового количества очков.

4.6. Выводы по главе 4

В ходе статистического моделирования исходов футбольных матчей были получены следующие результаты:

- **Адекватность модели Пуассона:** Подтверждена возможность использования распределения Пуассона для оценки силы атаки и защиты команд.
- **Эффективность модификации Диксона-Коулза:** Введение параметра зависимости $\rho = -0.0469$ позволило скорректировать вероятности для низких счетов. Это привело к стабильному, хотя и небольшому росту точности прогнозирования исходов.
- **Прогностическая ценность симуляций:** Метод Монте-Карло продемонстрировал высокую надежность в долгосрочном

планировании. Симуляция 10 000 итераций сезона позволила довольно точно определить фаворитов лиги и количество очков.

Таким образом, статистический подход на основе распределения Пуассона является эффективным инструментом первичного анализа, однако для достижения более высокой точности требуется переход к методам машинного обучения, которые будут рассмотрены в следующей главе.

ГЛАВА 5. ПРИМЕНЕНИЕ МЕТОДОВ МАШИННОГО ОБУЧЕНИЯ

В данной главе исследуется эффективность алгоритмов машинного обучения для решения двух фундаментальных задач футбольной индустрии: классификации исходов матчей и прогнозирования рыночной стоимости футболистов. Переход от статистических моделей к обучению с учителем позволяет учитывать нелинейные зависимости и более сложную структуру признаков.

5.1. Классификация исходов матчей

Для классификации результатов (победа хозяев, ничья, победа гостей) использовались данные о предматчевой форме команд, атакующих рейтингах и показателях xG.

В ходе исследования были протестированы четыре модели: логистическая регрессия, случайный лес, а также алгоритмы градиентного бустинга — XGBoost и CatBoost. Метрики качества на тестовой выборке представлены в таблице.

Модель	Accuracy	ROC-AUC	Log-Loss
Логистическая регрессия	0.6464	0.812	0.7690
Случайный лес	0.7407	0.903	0.5818
Градиентный бустинг (XGBoost)	0.7552	0.914	0.5259
Градиентный бустинг (CatBoost)	0.7599	0.916	0.5330

Таблица 5.1. Сравнительная эффективность моделей классификации исходов матчей

Анализ таблицы показывает, что алгоритмы градиентного бустинга существенно превосходят базовую логистическую регрессию. CatBoost продемонстрировал наилучшую точность, что свидетельствует о его способности эффективно разделять исходы матчей даже в условиях высокой неопределенности. Примечательно, что точность моделей ML оказалась на 20–25% выше, чем у классических пуассоновских моделей из главы 4, что подтверждает гипотезу о важности учета нелинейных взаимодействий признаков.




Рис. 5.1. Матрица ошибок модели CatBoost

Анализ матрицы ошибок показывает, что модель лучше всего справляется с предсказанием побед хозяев, несколько хуже — с ничейными исходами, что типично для футбольных данных из-за высокой стохастичности.




Рис. 5.2. Топ-7 наиболее важных признаков для CatBoost

Анализ важности признаков подтверждает, что наибольшее влияние на прогноз оказывает суммарное количество голов и разница ожидаемых голов.

5.2. Регрессия для прогнозирования трансферной стоимости игроков

Прогнозирование рыночной стоимости футболистов — это задача регрессии, где целью является минимизация разности между предсказанной и фактической стоимостью. Данный раздел критически важен для автоматизации систем скаутинга и финансового планирования клубов.

Оценка точности регрессионных моделей

Для решения задачи использовались регрессионные версии XGBoost и CatBoost. В качестве метрик оценки применялись метрики MAE, RMSE и R^2 . Результаты представлены в таблице.

Модель	RMSE (млн €)	MAE (млн €)	R^2
XGBoost	0.20	0.18	0.803
CatBoost	0.19	0.16	0.827

Таблица 5.2. Результаты прогнозирования стоимости игроков

Анализ таблицы показывает, что модель CatBoost продемонстрировала наилучшие результаты, объясняя 82.7% дисперсии целевой переменной. Средняя абсолютная ошибка составила 0.16 млн евро, что свидетельствует о высокой предсказательной способности модели.




Рис. 5.3. Топ-7 наиболее важных признаков для CatBoost

Анализ важности признаков в регрессионной модели CatBoost показал, что доминирующими факторами являются общий рейтинг и потенциал. Эти метрики эффективно агрегируют игровое мастерство. Также значительное влияние оказывает возраст.

5.3. Выводы по главе 5

1. **Превосходство ансамблевых методов:** Использование алгоритмов градиентного бустинга обеспечило точность прогнозирования исходов матчей на уровне 76%, что существенно выше результатов классических статистических методов и базовой логистической регрессии.
2. **Высокое качество оценки стоимости:** Регрессионная модель CatBoost показала коэффициент детерминации $R^2 = 0.827$, что позволяет использовать ее для объективной оценки трансферной стоимости игроков.

Таким образом, пятая глава полностью раскрывает потенциал современных методов машинного обучения в спортивной индустрии, обеспечивая надежный фундамент для дальнейшего исследования сегментации игроков и анализа временных рядов.

ГЛАВА 6. КЛАСТЕРИЗАЦИЯ И СЕГМЕНТАЦИЯ ФУТБОЛИСТОВ ПО СТИЛЮ ИГРЫ

В данной главе рассматривается задача автоматической сегментации игроков на основе их игровых характеристик. Использование алгоритмов обучения без учителя позволяет выявлять скрытые игровые роли и находить аналоги игроков для скаутинга, подбора замен и анализа трансферных перспектив.

6.1. Методология и подготовка данных

Для проведения кластеризации был сформирован расширенный набор из 40 признаков. В качестве основных алгоритмов были выбраны:

1. **К-Means** – для разделения на чётко выраженные группы по средним характеристикам.
2. **Агломеративная кластеризация** – для визуального анализа иерархии.
3. **DBSCAN** – для выявления кластеров произвольной формы и шума.
4. **Гауссовы смеси** – для вероятностной сегментации.

Перед обучением данные были подвергнуты стандартному масштабированию, так как алгоритмы, основанные на расстоянии, чувствительны к разному масштабу признаков.

6.2. Определение оптимального количества кластеров

Для определения оптимального числа групп при использовании метода К-Means применялись метод «локтя» и анализ коэффициента силуэта.

Число кластеров (k)	Инерция	Silhouette Score
2	92 360	0,542
3	68 443	0,298
4	60 460	0,218
5	54 784	0,202
6	49 576	0,220
7	46 967	0,207
8	44 993	0,189
9	43 647	0,178
10	42 507	0,168

Таблица 6.1. Оценка качества кластеризации K-Means для разного числа кластеров

Снижение Silhouette Score вдвое при переходе к трем группам свидетельствует о том, что данные в 40-мерном пространстве фундаментально делятся на две глобальные страты.

6.3. Сравнение алгоритмов кластеризации

Все алгоритмы были оценены по коэффициенту силуэта. Лучшие результаты показали К-Means, агломеративная кластеризация и Гауссовы смеси.

Алгоритм	Silhouette Score
К-Means	0,542
Агломеративная	0,542
Гауссовы смеси	0,542
DBSCAN	0,238

Таблица 6.2. Сравнительная эффективность алгоритмов кластеризации

DBSCAN продемонстрировал низкое качество и выделил большое количество шума, что делает его неприменимым для данной задачи.




Рис. 6.1. Сравнение алгоритмов кластеризации

6.4. Интерпретация кластеров

В таблице приведены средние значения 10 признаков для каждого кластера.

Признак	Кластер 0	Кластер 1	Разница
Общий рейтинг	73,9	74,3	+0,4
Потенциал	76,4	76,1	–0,3
Возраст	27,3	29,7	+2,4
Защита	57,9	26,2	–31,7
Отбор стоя	59,1	14,9	–44,2
Отбор в подкате	55,9	14,7	–41,2
Сила удара	67,8	63,4	–4,4
Скорость	50,2	73,6	+23,4
Дриблинг	40,4	72,5	+32,1
Завершение атаки	53,8	78,4	+24,6

Таблица 6.3. Средние значения ключевых признаков по кластерам

Анализ таблицы позволил дать следующую интерпретацию:

- **Кластер 0 – «Защитники/опорные полузащитники»:**
Высокие показатели отбора и защиты, однако уступают по навыкам атаки.
- **Кластер 1 – «Атакующие игроки»:**
Защитные навыки заметно ниже, но значительно выше показатели скорости, дриблинга и завершения атаки.

6.5. Выводы по главе 6

1. Оптимальная сегментация достигается при разделении на два кластера. Выделение более мелких групп не улучшает качество и снижает интерпретируемость.
2. Сравнение алгоритмов показало, что K-Means, агломеративная кластеризация и Гауссовы смеси дают одинаково высокое качество. DBSCAN не применим из-за высокой плотности данных и большого числа шумовых точек.

ГЛАВА 7. ВРЕМЕННЫЕ РЯДЫ И НЕЙРОСЕТЕВЫЕ МОДЕЛИ

Применение нейронных сетей в футбольной аналитике обосновано их способностью к аппроксимации сложных нелинейных функций и автоматическому выявлению взаимодействий между признаками высокого порядка. В данной главе рассматриваются два типа архитектур: полносвязные сети для классификации исходов и рекуррентные сети для анализа временных рядов.

7.1. Классификация исходов матчей с помощью MLP

Для оценки потенциала глубокого обучения на табличных данных был реализован многослойный перцептрон (MLP). Архитектура сети была спроектирована как последовательная модель со следующей конфигурацией:

- **Входной слой:** Количество нейронов соответствует числу входных предикторов.
- **Первый скрытый слой:** 128 нейронов с функцией активации ReLU. Данный слой отвечает за первичное выделение нелинейных паттернов.
- **Второй скрытый слой:** 64 нейрона с функцией активации ReLU. Уменьшение размерности способствует агрегации наиболее значимых сигналов.
- **Слои регуляризации:** С коэффициентом 0,2 после каждого скрытого слоя для предотвращения переобучения модели на тренировочной выборке.
- **Выходной слой:** 3 нейрона с функцией активации, возвращающей вероятностное распределение по трем классам: победа хозяев, ничья, победа гостей.

Обучение проводилось на данных сезонов 2014–2021 гг. с использованием оптимизатора Adam, обеспечивающего адаптивную скорость обучения для каждого веса. Эффективность оценивалась на отложенной тестовой выборке матчей 2022–2023 гг. Полученные метрики представлены в Таблице.

Метрика	Значение
Accuracy	0.7494
Log-Loss	0.5940
ROC-AUC	0.8956

Таблица 7.1. Метрики качества MLP для прогноза исходов матчей

Сравнительный анализ показал, что MLP значительно превосходит статистические модели, однако незначительно уступает CatBoost. Это

подтверждает выводы современных исследований о том, что для задач на структурированных данных градиентный бустинг зачастую эффективнее полносвязных нейросетей из-за лучшей обработки категориальных признаков.

7.2. Анализ временных рядов

Для исследования были сформированы временные ряды рыночной стоимости игроков с месячным шагом. Данные подвергнуты нормализации, что является необходимым условием для стабильной работы нейронных сетей. В качестве базовых статистических моделей выбраны ARIMA и экспоненциальное сглаживание, которые сопоставляются с рекуррентной нейронной сетью LSTM.

Для прогнозирования стоимости разработана глубокая нейронная сеть с архитектурой LSTM, способная улавливать долгосрочные зависимости в последовательностях. Описание структуры сети:

- **Входной слой:** принимает тензор размерности (12,1), что соответствует истории стоимости за последние 12 месяцев.
- **Первый скрытый слой:** содержит 64 блока с функцией активации.
- **Слой регуляризации:** с коэффициентом 0.2 для борьбы с переобучением на малых выборках.
- **Второй скрытый слой:** содержит 32 блока, агрегирующих признаки в финальный вектор состояния.
- **Второй слой регуляризации:** также с коэффициентом 0.2.
- **Выходной слой:** один полносвязный нейрон, возвращающий предсказанное значение стоимости на 13-й месяц.

Оптимизация весов проводилась методом Adam с минимизацией среднеквадратичной ошибки. Обучение включало 80 эпох с использованием механизма ранней остановки для предотвращения деградации модели при росте ошибки на валидационной выборке.

7.3. Сравнительный анализ точности прогнозов

Модель ARIMA и экспоненциальное сглаживание с аддитивной сезонностью периода 12 обучаются на 75% наиболее ранних точках ряда; прогноз строится на оставшиеся 25%.



Рис. 7.1. Прогноз рыночной стоимости для игрока 51894

Для каждого игрока рассчитаны метрики RMSE, MAE и MAPE на едином тестовом периоде. В таблице приведены результаты по 10 игрокам, имеющим максимальное число наблюдений стоимости.

Игрок ID	ARIMA MAPE	Эксп. сглаж. MAPE	LSTM MAPE
179184	63,1%	149,1%	34,8%
238809	63,0%	50,7%	28,7%
186590	33,1%	20,9%	51,1%
68863	83,5%	185,8%	44,9%
278654	116,4%	170,5%	52,4%
182877	171,9%	104,4%	26,2%
51894	58,4%	120,3%	18,2%
216662	116,4%	170,0%	37,7%
238266	39,2%	146,0%	76,2%
183288	58,9%	40,1%	84,7%

Таблица 7.2. Сравнение точности моделей временных рядов

Анализ показывает, что LSTM превосходит классические модели в 7 случаях из 10 по показателю MAPE, однако разрыв не всегда значителен. Это свидетельствует о высокой чувствительности LSTM к качеству и длине обучающей выборки: при резких изменениях стоимости в тестовом периоде, не имеющих аналогов в истории, нейросетевая модель склонна к переобучению и неоправданно большим ошибкам.

7.4. Выводы по главе 7

1. **Эффективность LSTM:** Нейросетевая модель демонстрирует более высокую гибкость по сравнению с ARIMA, успешно адаптируясь к нелинейному росту стоимости.

2. **Ограничения модели:** Выявлена критическая зависимость LSTM от длины обучающей последовательности. При резких рыночных потрясениях, не имевших аналогов в истории игрока, модель склонна к значительным погрешностям.

Если говорить про перспективы исследований, то ошибки прогноза указывают на то, что использование только временного ряда стоимости недостаточно. Дальнейшие исследования должны быть направлены на создание мультимодальных сетей, объединяющих временные ряды стоимостей с динамическими игровыми метриками.

ЗАКЛЮЧЕНИЕ

В ходе выполнения выпускной квалификационной работы был проведен комплексный сравнительный анализ эффективности статистических моделей, алгоритмов машинного обучения и нейронных сетей для решения задач прогнозирования в профессиональном футболе, что позволило сформулировать следующие научные и прикладные выводы.

Итоги сравнительного анализа моделей

Проведенное исследование продемонстрировало дихотомию между интерпретируемостью и точностью. Сравнение подходов показало, что выбор оптимального метода зависит от специфики решаемой задачи и характера доступных данных.

Подход Задача	Статистический подход	Машинное обучение	Глубокое обучение
Исход матча (Accuracy)	0.536 (Диксон-Коулз)	0.759 (CatBoost)	0.749 (MLP)
Стоимость игрока (R ²)	0.646 (LogReg)	0.827 (CatBoost)	0.745 (LSTM)

Таблица 8.1. Итоговая сводная таблица эффективности подходов

- Статистические модели:** оказались незаменимыми для фундаментального анализа. Модель Диксона-Коулза позволяет оценивать параметры атаки и защиты, критически важные для разработки тактики. Линейная регрессия показала высокий базовый результат, что объясняется качественной предобработкой экспертных признаков.
- Машинное обучение:** показали наилучшую общую точность. Прирост точности прогнозирования исходов матчей составил 22% относительно статистического порога. Модели успешно учитывают нелинейные зависимости между xG, формой команд и составом, обеспечивая наиболее надежный результат для предматчевой аналитики.
- Глубокое обучение:** полносвязные нейросети показали результат, сопоставимый с ансамблями, но требующий более сложной настройки. Рекуррентные сети выявили уникальный потенциал в моделировании динамики стоимости, достигнув превосходства над ARIMA в 70% случаев. Основным ограничением остается чувствительность к аномальным рыночным скачкам.

Применимость для спортивной аналитики и скаутинга

Разработанный инструментарий может быть использован в двух ключевых сценариях:

1. **Предматчевый анализ:** Автоматизированная симуляция исходов матча методом Монте-Карло позволяет клубам оценивать вероятностные риски и корректировать тактику в зависимости от силы соперника.
2. **Трансферная политика и скаутинг:** Алгоритмы кластеризации позволяют сегментировать игроков на «атакующие» и «защитные» блоки, что упрощает поиск аналогов при замене лидеров или поиске недооцененных талантов.

Взаимодополнение подходов

Исследование подтвердило гипотезу о том, что статистический и ML-подходы не являются взаимоисключающими. Наиболее эффективной признана гибридная архитектура:

- Статистические модели служат для фильтрации данных и создания надежных базовых признаков.
- ML-модели используют эти рейтинги для финального прогноза.
- Нейросети на базе LSTM дополняют картину, прогнозируя долгосрочный тренд изменения игрока во времени.

Такая «трехуровневая» система обеспечивает баланс между математической строгостью, точностью и динамической гибкостью.

Перспективы дальнейших исследований

Дальнейшее развитие работы может идти по двум направлениям:

1. **Обогащение данных:** интеграция данных отслеживания и компьютерного зрения для анализа перемещений игроков без мяча.
2. **Системная оптимизация:** с точки зрения системного программирования перспективным является перенос обучения нейросетей на GPU и разработка веб-интерфейса для визуализации аналитических радарных диаграмм в режиме реального времени.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

- [1] Понарин Э.Д., Лисовский А.В., Зеликова Ю.А., «Модели для пуассоновских зависимых переменных: можно ли прогнозировать результативность футбольных матчей?» *Социология: методология, методы, математическое моделирование (Социология: 4М)*, № 36, стр. 36-64, 2016.
- [2] Рубинштейн Е.Ю., Тихонович Д.Д., Федосюк Л.П., «Анализ вероятностей спортивных событий: теория и практическое применение статистических моделей» *Международный научный журнал*, 2024.
- [3] K. Loukas, «Predicting Football Match Results Using a Poisson Regression Model» *Applied Sciences*, 2024.
- [4] Довгаль А.А., «Предсказание результатов футбольных матчей с помощью машинного обучения: магистерская диссертация» НИУ ВШЭ, 2025.
- [5] Магомедов Р.С., «Прогнозирование исходов футбольных матчей с использованием алгоритмов машинного обучения с учителем: магистерская диссертация» НИУ ВШЭ, 2024.
- [6] Ван Ц. (науч. рук. Добренко Н.В.), «Использование машинного обучения для анализа и прогнозирования результатов футбольных матчей» *Сборник тезисов докладов конгресса молодых ученых*, 2023.
- [7] «Сравнительный анализ методов машинного обучения с применением полинома Колмогорова-Габора для прогнозирования результатов спортивных событий» *Технико-экономические исследования*, № 4, стр. 102–148, 2025.
- [8] Байшев О.М. (науч. рук. Крылатов А.Ю.), «Прогнозирование исходов спортивных событий с использованием методов машинного обучения: выпускная квалификационная работа» СПбГУ, СПб, 2024.
- [9] Коновалов М.С., Емельянова Т.В., «Прогнозирование трансферной стоимости футболистов с использованием различных регрессионных методов и алгоритмов машинного обучения» *Все грани математики и механики: сборник статей Всероссийской молодежной научной конференции*, стр. 76–80, 2024.

- [10] Айбатуллин Т.А., Касимова А.Х., «ИИ и трансферный рынок: автоматизация оценки стоимости и потенциала футболистов» *Международный научный журнал*, 2025.
- [11] Biao Geng, «Predicting Football Player Transfer Values Using Bagging and Hybrid Machine Learning Approaches» *Informatica*, стр. 121–134, 2025.
- [12] I. Behravan, «A novel machine learning method for estimating football players' value in the transfer market» *Journal of Economics, Finance and Administrative Science*, стр. 1–26, 2025.
- [13] Андреева Е.А., Храмов И.С., «Применение нейронной сети для предсказания результатов футбольных матчей» *Математические методы управления: сборник научных трудов*, стр. 19-25, 2015.
- [14] T. Quan and Y. Luo, «Advanced Football Match Winning Probability Prediction: A CNN-BiLSTM Model with Player Compatibility and Dynamic Lineup Analysis» *International Journal of Advanced Computer Science and Applications*, стр. 557–566, 2025.
- [15] Manafzadeh F., Eslahchi C., Nobari H, «Success Score: A Deep Learning Framework for Predicting Football Match Outcomes and Evaluating Team Performance» *Research Square (Preprint)*, 2025.