Министерство науки и высшего образования Российской Федерации
Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт

Работа допущена к защите

Руководитель образовательной программы

«Прикладная математика и информатика»

_____ К.Н. Козлов

«___» _____2026 г.

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

РАБОТА БАКАЛАВРА

СТАТИСТИЧЕСКОЕ МОДЕЛИРОВАНИЕ И ПРОГНОЗИРОВАНИЕ В ФУТБОЛЕ НА ОСНОВЕ ДАННЫХ МАТЧЕВОЙ СТАТИСТИКИ И МАШИННОГО ОБУЧЕНИЯ

по направлению подготовки 01.03.02 Прикладная математика и информатика
Направленность (профиль) 01.03.02_02 Системное программирование

Выполнил
студент гр. 5030102/20202 С.Е. Тишковец

Руководитель
д.т.н., профессор ВШПМиВФ Ф.А. Новиков

Консультант
по нормоконтролю Д.Ю. Иванов

Санкт-Петербург

2026

РЕФЕРАТ

На 55 с., 10 рис., 5 табл., 3 прил.

Ключевые слова: футбол, статистическое моделирование, машинное обучение, прогнозирование, спортивная аналитика.

Тема выпускной квалификационной работы: «Статистическое моделирование и прогнозирование в футболе на основе данных матчевой статистики и машинного обучения».

Настоящая работа посвящена разработке и сравнению статистических моделей и моделей машинного обучения для анализа футбольных данных, с акцентом на прогнозирование исходов матчей и оценку рыночной стоимости игроков. В условиях роста объема доступных данных в футболе (матчевая статистика, характеристики игроков, трансферные значения) предлагается интегрированный подход, сочетающий классические статистические методы с современными алгоритмами машинного обучения для повышения точности прогнозов и их интерпретируемости.

Основные задачи работы:

1. Сбор, очистка и объединение данных из открытых источников.
2. Разведочный анализ данных (EDA), исследование базовых распределений и корреляций, вычисление производных признаков.
3. Статистическое моделирование: построение и валидация модели результата матча на основе распределения Пуассона с учетом атакующих и защитных показателей команд. Проверка статистических гипотез при сравнении групп игроков разных лиг.
4. Модели машинного обучения: классификация исхода матча и регрессия для прогнозирования трансферной стоимости игроков. Кластеризация для поиска групп игроков с похожими характеристиками.
5. Глубокое обучение для временных рядов: рекуррентные нейронные сети для прогнозирования динамики формы и стоимости игроков во времени.
6. Сравнительный анализ точности и интерпретируемости всех построенных моделей.

Работа проведена на основе открытых наборов данных из источников таких как Kaggle и Transfermarkt, где собиралась значительная часть фактического материала: статистика матчей, характеристики игроков и трансферные данные за период 2015–2025 годов. Были проведены расчеты, демонстрирующие влияние различных признаков на прогнозы, включая корреляционный анализ и симуляции исходов матчей..

В результате был проанализирован комплекс данных по пяти ведущим европейским лигам, разработаны модели, показавшие улучшение точности

прогнозов на 10–15% по сравнению с базовыми подходами. Сравнение выявило, что статистические модели (на основе распределения Пуассона) превосходят в интерпретируемости, в то время как модели машинного обучения (такие как XGBoost и рекуррентные сети) обеспечивают высшую точность в сложных сценариях.

Для достижения указанных результатов в работе использованы современные информационные технологии и программные инструменты: язык программирования Python (библиотеки pandas, scikit-learn, XGBoost, CatBoost, TensorFlow/Keras), базы данных FIFA и статистики матчей (SoFIFA, Kaggle), API Transfermarkt, а также облачные сервисы для хранения и обработки данных.

ABSTRACT

On 55 pages, 10 figures, 5 tables, 3 appendices.

Keywords: football, predictive modeling, machine learning, sports analytics, match outcome, player valuation.

The subject of the graduate qualification work is «Statistical Modeling and Forecasting in Football Based on Match Statistics Data and Machine Learning».

This work is devoted to the development and comparison of statistical and machine learning models for analyzing football data, with a focus on predicting match outcomes and estimating players' market values. In the context of the growing volume of available data in football (match statistics, player attributes, transfer values), an integrated approach is proposed, combining classical statistical methods with modern machine learning algorithms to improve the accuracy and interpretability of forecasts.

The research set the following goals:

1. Collection, cleaning, and integration of data from various open sources.
2. Conducting exploratory data analysis and computing derived features.
3. Statistical modeling: building and validating a match outcome prediction model based on the Poisson distribution, using historical data on teams' attack and defense; applying statistical hypothesis testing methods to compare player groups.
4. Machine learning: match outcome prediction using classification algorithms and neural networks; player transfer value prediction as a regression task; player clustering for finding groups with similar characteristics.
5. Deep learning for time series: forecasting player form and value using recurrent neural networks.
6. Comparative analysis of the accuracy and interpretability of all constructed models.

The work was performed based on open datasets from sources such as Kaggle and Transfermarkt, where a significant portion of the factual material was collected: match statistics, player attributes, and transfer data for the period 2015–2025. Calculations were conducted to demonstrate the impact of various features on predictions, including correlation analysis and match outcome simulations.

The result was an analysis of data from the top-5 European leagues, with developed models showing a 10–15% improvement in prediction accuracy compared to baseline approaches. The comparison revealed that statistical models (Poisson-based) excel in interpretability, while machine learning models (such as XGBoost and recurrent networks) provide superior accuracy in complex scenarios.

To achieve these results, the following IT tools and resources were used: Python (with libraries pandas, scikit-learn, XGBoost, CatBoost,

TensorFlow/Keras), open databases of FIFA and match statistics (SoFIFA, Kaggle, Transfermarkt), and cloud computing services for data processing.

СПИСОК УСЛОВНЫХ ОБОЗНАЧЕНИЙ И СОКРАЩЕНИЙ

1. **xG (Expected Goals)** — ожидаемые голы; метрика вероятности взятия ворот.
2. **EDA (Exploratory Data Analysis)** — разведочный анализ данных.
3. **RMSE (Root Mean Square Error)** — среднеквадратичная ошибка.
4. **MAE (Mean Absolute Error)** — средняя абсолютная ошибка.
5. **LSTM (Long Short-Term Memory)** — рекуррентная нейронная сеть с долгой краткосрочной памятью.
6. **ARIMA (AutoRegressive Integrated Moving Average)** — интегрированная модель авторегрессии — скользящего среднего.
7. **DBSCAN (Density-Based Spatial Clustering of Applications with Noise)** — алгоритм плотностной кластеризации.
8. **MLE (Maximum Likelihood Estimation)** — метод максимального правдоподобия.
9. **API (Application Programming Interface)** — программный интерфейс приложения.
10. **ROC-AUC** — площадь под кривой ошибок; метрика качества классификации.
11. **IQR (Interquartile Range)** — межквартильный размах; мера разброса данных.
12. $\boldsymbol{\alpha}$ — уровень статистической значимости (вероятность ошибки первого рода)
13. **p-value** — уровень значимости; вероятность ошибки первого рода в гипотезном тестировании.
14. $\boldsymbol{H_0}$ — нулевая гипотеза; предположение об отсутствии статистически значимых различий или связей.
15. $\boldsymbol{H_1}$ — альтернативная гипотеза; предположение о наличии значимых различий или эффектов.
16. $\boldsymbol{\lambda}$ — параметр распределения Пуассона, характеризующий среднюю интенсивность событий.
17. $\boldsymbol{\chi^2}$ — статистический критерий для проверки согласия распределений или независимости признаков.

18. $\boldsymbol{U}$ — эмпирическая статистика непараметрического критерия Манна-Уитни.

19. $\boldsymbol{t}$ — статистика критерия Стьюдента для сравнения средних значений.

20. $\boldsymbol{\rho}$ — коэффициент корреляции Пирсона, мера линейной зависимости.

21. $\boldsymbol{r_s}$ — коэффициент ранговой корреляции Спирмена для оценки монотонных связей.

22. $\boldsymbol{df}$ — число степеней свободы (degrees of freedom).

23. $\boldsymbol{CI}$ — доверительный интервал (Confidence Interval).

24. $\boldsymbol{Z}$**-score** — стандартизованная оценка, показывающая количество стандартных отклонений от среднего.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ 9
ГЛАВА 1. ОБЗОР СУЩЕСТВУЮЩЕЙ ЛИТЕРАТУРЫ 11
1.1. Статистические модели в прогнозировании исходов матчей 11
1.2. Машинное обучение в предсказании исходов матчей и стоимости игроков 12
1.3. Глубокое обучение и временные ряды 12
1.4. Итоги обзора 13
ГЛАВА 2. ИСТОЧНИКИ И ОПИСАНИЕ ДАННЫХ 14
2.1. Перечень используемых ресурсов 14
2.2. Описание структуры и фокуса данных 14
2.3. Предобработка данных 15
2.4. Формирование признаков 15
ГЛАВА 3. РАЗВЕДОЧНЫЙ И СТАТИСТИЧЕСКИЙ АНАЛИЗ ДАННЫХ (EDA) 17
3.1. Анализ базовых распределений и описательная статистика лиг 17
3.2. Проверка статистических предположений Пуассона для количества голов 19
3.3. Корреляционный анализ игровых метрик и экономических показателей 20
3.4. Проверка статистических гипотез: межлигивые и межгрупповые сравнения 22
3.5. Построение доверительных интервалов 22
3.6. Визуализация данных и выявление паттернов 23
3.7. Анализ временных рядов и динамика формы 25
3.8. Выводы по главе 3 26
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ 28

ВВЕДЕНИЕ

Постановка проблемы

Современный футбол генерирует огромные объемы данных: детальную статистику матчей, игровые показатели футболистов (количество ударов, передач, т.д.), а также информацию о трансферных операциях и тренировочном процессе. Анализ этих данных позволяет перейти от субъективных оценок игроков и команд к объективным метрикам. Широкое использование таких метрик клубами и аналитическими службами демонстрирует востребованность количественного подхода.

Однако традиционные подходы, основанные на экспертных мнениях или простых статистических агрегациях, часто недостаточно точны для прогнозирования динамичных событий, таких как исходы матчей или изменения рыночной стоимости игроков. Проблема заключается в необходимости интеграции разнородных данных и применения гибридных моделей, способных учитывать стохастическую природу футбола — случайные факторы вроде травм, погоды или судейских решений.

В настоящей работе предлагается решение через синтез статистического моделирования и машинного обучения, что позволит повысить точность прогнозов и их применимость в реальной аналитике.

Актуальность предиктивной аналитики в футболе

В современном футболе данные стали ключевым активом для клубов, скаутов и аналитиков. По данным отчетов FIFA и Deloitte, глобальный рынок трансферов превысил 8 млрд долларов в 2024 году, где точная оценка стоимости игроков может сэкономить миллионы. Аналогично, прогнозирование исходов матчей влияет на стратегии команд, букмекерские коэффициенты и фанатский контент.

Актуальность темы обусловлена экспоненциальным ростом данных: с развитием технологий отслеживания объем матчевых метрик удваивается ежегодно. Классические статистические модели, такие как распределение Пуассона для голов, доказали свою эффективность, но в комбинации с машинным обучением и глубоким обучением они достигают новых уровней точности — до 70% для предсказания победителей в ведущих лигах. В России, с учетом развития Российской Премьер-лиги и интеграции с европейскими стандартами, такие модели могут способствовать повышению уровня отечественного футбола.

Цель и мотивация

Цель работы — разработать и сравнить эффективность статистических моделей и моделей машинного обучения для ключевых задач футбольной аналитики: прогнозирования результатов матчей и оценки рыночной стоимости игроков на основе данных FIFA и матчевой статистики. Это включает анализ статистики игроков и команд, применение машинного обучения и глубокого обучения для выявления паттернов и симуляций.

Мотивация кроется в практической ценности: данные помогают принимать спортивные решения и коммерческие. Например, точный прогноз стоимости позволяет клубам идентифицировать таланты из низших лиг, минимизируя риски, а модели матчей — оптимизировать ставки и медиаконтент. В итоге, работа способствует переходу к подходу, основанному на доказательствах, в футболе, где объективные модели дополняют человеческий опыт.

ГЛАВА 1. ОБЗОР СУЩЕСТВУЮЩЕЙ ЛИТЕРАТУРЫ

В данной главе представлены основные исследования, лежащие в основе статистического моделирования и машинного обучения в футбольной аналитике. Обзор охватывает классические подходы (распределение Пуассона для голов), современные методы (ML-алгоритмы, бустинг, нейронные сети) и их применение в задачах прогнозов и оценки игроков.

1.1. Статистические модели в прогнозировании исходов матчей

Футбольная аналитика представляет собой активно развивающуюся область исследования. Существуют многочисленные публикации по прогнозированию результатов матчей и оценке игроков. Одним из классических подходов к предсказанию футбольных матчей является использование пуассоновских моделей. В статье [1] авторы проверяют соответствие количества голов Пуассоновскому процессу, используя данные Английской Премьер-лиги за 10 сезонов. Модель оценивает параметры через метод максимального правдоподобия, достигая точности 55% для предсказания победителей. Авторы отмечают, что Пуассоновская модель хорошо справляется с независимыми событиями, но игнорирует корреляции между атаками команд. Аналогично, в работе [2] предлагается параметрическая модель для предсказания голов, интегрирующая рейтинги атаки и защиты. Результаты на данных пяти лиг показывают среднеквадратичную ошибку 1,2 для количества голов, с симуляцией сезонов для оценки вероятностей.

Ключевое ограничение такого подхода — статичность модели, не учитывающая временные изменения формы.

Байесовские расширения Пуассоновской модели улучшают гибкость. В работе [3] применяется гамма-приор для учета явления, при котором наблюдаемая дисперсия данных превышает ожидаемую на основе конкретной статистической модели, тестируя на данных Главной лиги футбола. Модель достигает 62% точности, превосходя базовую Пуассоновскую модель на 7%. Авторы подчеркивают интерпретируемость: параметры напрямую связаны с силой команд. В контексте данных FIFA работа [4] использует глобальные турниры, включая Чемпионат мира, для точного предсказания счетов. В качестве результата: вероятность точного счета 15–20%, с рекомендациями для букмекерства.

Гипотезное тестирование интегрируется для сравнения групп. Например, в обзорах [5] t-критерий и критерий Манна-Уитни применяются для анализа различий между лигами, подтверждая значимость метрик вроде ожидаемых голов.

Эти работы показывают практическую ценность статистических моделей для оценки вероятностей исходов и позиций команд в таблице на основе забитых и пропущенных мячей.

1.2. Машинное обучение в предсказании исходов матчей и стоимости игроков

Переход к машинному обучению усилил точность за счет нелинейных зависимостей. В исследовании [6] сравниваются классификаторы на данных Английской Премьер-лиги, достигая 68% точности. Авторы выделяют следующие признаки: форма, история встреч, ожидаемые голы. Главное ограничение — риск переобучения на малых наборах данных. Аналогично, работа [7] использует XGBoost для матчей Чемпионата мира, с точностью 72% на тестовых данных. Модель обобщается на разные турниры.

В контексте стоимости игроков ML доминирует. Исследование [8] применяет регрессию на данных, среднеквадратичная ошибка 3,5 млн евро. Выделяются следующие признаки: возраст, голы, контракты. Работа [9] сравнивает CatBoost и нейронные сети, показывая улучшение на 12% в сравнении с линейной регрессией. Основной фокус на характеристиках FIFA (таких как скорость, дриблинг).

Для выявления «аналогов» и определения ролей используется кластеризация: работа [10] использует метод K-средних на полевых данных, выявляя кластеры талантов. Метрика коэффициента силуэта в районе 0,65, с приложением к скаутингу.

1.3. Глубокое обучение и временные ряды

В области глубокого обучения и временных рядов пока встречаются ограниченные исследования. Модели временных рядов (ARIMA, экспоненциальное сглаживание) применяются для прогнозирования тренда очков команды или изменения формы игрока. Рекуррентные нейронные сети (LSTM, GRU) позволяют учесть сложные нелинейные и долговременные зависимости. Так, в качестве примера можно отметить применение [11] рекуррентных сетей и XGBoost для прогноза числа голов футболиста (на примере Криштиану Роналду), где рекуррентные сети давали более оптимистичный прогноз, хотя случайный лес оказывался более стабильным.

В целом, модели глубокого обучения применяются для учета временных зависимостей, но их использование в футбольной аналитике требует дальнейшего изучения.

1.4. Итоги обзора

Сопоставление существующих исследований подтверждает, что сочетание классических статистических методов и современных алгоритмов машинного обучения является перспективным направлением в футбольной аналитике. Ключевые преимущества такого сочетания — баланс между интерпретируемостью и точностью прогнозов. В связи с этим выбранный в настоящей работе комплекс задач представляется обоснованным и своевременным. Полученные в литературе методические наработки и эмпирические результаты служат теоретической и методической основой для дальнейшей экспериментальной части исследования.

ГЛАВА 2. ИСТОЧНИКИ И ОПИСАНИЕ ДАННЫХ

В данной главе рассматривается процесс формирования информационной базы исследования, описываются ключевые источники данных, а также алгоритмы их предобработки и проектирования признаков.

2.1. Перечень используемых ресурсов

Для обеспечения репрезентативности выборки в работе реализован синтез данных из четырех типов источников:

1. **Официальные ресурсы федераций и международных организаций**: сайты FIFA.com и UEFA.com использовались для получения официальных рейтингов национальных сборных и клубных коэффициентов, определяющих долгосрочный уровень конкурентоспособности.

2. **Агрегаторы продвинутой статистики**: ресурс FBref.com является основным источником матчевых метрик. Отсюда извлекались данные по ожидаемым голам (xG), точности передач под давлением и продвижению мяча.

3. **Открытые научные датасеты**:

   - Платформа **Kaggle** предоставила архивные данные по европейским лигам за период 2014–2023 гг., включая подробные протоколы матчей.
   - Репозиторий **arno.uvt.nl** использовался для доступа к базам данных, содержащим оценки скрытых характеристик игроков (потенциал, ментальная устойчивость).

4. **Специализированные API и игровые данные**:

   - **Transfermarkt API**: использовалось для сбора динамики рыночной стоимости игроков и данных о сроках контрактов.
   - **SoFIFA.com**: источник атрибутов игроков (скорость, дриблинг, физическая мощь), обновляемых на еженедельной основе.

Общий объем финальной выборки составил более 25 000 матчей и характеристики более 16 000 уникальных игроков.

2.2. Описание структуры и фокуса данных

Исследование сфокусировано на «Большой пятерке» европейских лиг, так как для них доступен наиболее полный набор продвинутых метрик:

- Английская Премьер-лига (EPL);
- Испанская Ла Лига (La Liga);
- Немецкая Бундеслига (Bundesliga);
- Итальянская Серия А (Serie A);
- Французская Лига 1 (Ligue 1).

Данные структурированы на двух уровнях:

- **Team-level (командный)**: результат матча, владение, xG, дистанция пробега, средний возраст состава.
- **Player-level (индивидуальный)**: биометрические данные, игровые показатели в конкретном матче, рыночная стоимость.

2.3. Предобработка данных

Предобработка проводилась в Python с использованием библиотек pandas, NumPy и SciPy для обеспечения качества данных перед моделированием. Основные шаги:

1. **Очистка данных**: пропуски в метриках xG для ранних сезонов импутировались медианными значениями по амплуа. Для выявления аномалий в трансферных стоимостях применен метод межквартильного размаха (IQR). В качестве выбросов были идентифицированы и обработаны записи с аномально высокой стоимостью, не подтвержденной игровыми метриками.

2. **Нормализация и масштабирование**: к атрибутам игроков применена Min-Max нормализация в диапазоне $[0,1]$, к временным рядам — стандартизация z-score. Это обеспечило совместимость данных из разных источников.

2.4. Формирование признаков

Для повышения предиктивной способности моделей спроектированы следующие группы признаков:

- **Временные (Date-based):** извлечение сезона и месяца для учета фактора «финишного рывка» команд в конце сезона.
- **Динамические (Time-based):** расчет лагов (предыдущие 5 матчей) и скользящих средних (rolling average) для xG и набранных очков.
- **Производные:** относительная сила команд (разница рейтингов), xG-дифференциал и индекс качества состава.

В соответствии с принципами построения предиктивных систем, данные разделены на обучающую (80%, 2014–2021) и тестовую (20%, 2022–

2023) выборки. Хронологический порядок разбиения исключает «заглядывание в будущее» и гарантирует обобщаемость результатов.

ГЛАВА 3. РАЗВЕДОЧНЫЙ И СТАТИСТИЧЕСКИЙ АНАЛИЗ ДАННЫХ (EDA)

Разведочный анализ данных (EDA) представляет собой критически важный этап в цикле статистического моделирования и машинного обучения, особенно в такой сложной предметной области, как профессиональный футбол. Основная задача EDA заключается не только в визуализации данных, но и в глубоком понимании структуры выборки, выявлении скрытых закономерностей, проверке статистических гипотез и валидации теоретических предположений, на которых базируются классические модели спортивного прогнозирования.

Футбольные данные по своей природе характеризуются высокой зашумленностью, наличием выбросов и сложными нелинейными зависимостями между игровыми показателями и итоговым результатом. Систематический подход к анализу, основанный на принципах математической статистики, позволяет отделить сигнал от шума и сформировать репрезентативный набор признаков для алгоритмов классификации и регрессии.

3.1. Анализ базовых распределений и описательная статистика лиг

Первым этапом EDA является изучение распределений ключевых метрик на уровне команд и игроков. Для исследования была сформирована выборка из более чем 16 тыс. матчей пяти ведущих европейских лиг за период 2014–2023 годов. Анализ описательных статистик позволяет сформировать «профиль» каждой лиги и выявить системные различия в их игровых стилях.

Распределение результативности и фактор домашнего поля

Количество голов в футболе является дискретной величиной с ограниченным диапазоном значений, что накладывает специфические требования к анализу. На протяжении десятилетнего периода наблюдения средняя результативность в европейских топ-лигах демонстрирует высокую степень стабильности, однако между чемпионатами сохраняются устойчивые различия.

Лига	Матчей в выборке	Ср. кол-во голов дома	Ср. кол-во голов на выезде	Общая результативность	Процент ничьих
Bundesliga	2754	1.684	1.311	2.995	24.7
EPL	3420	1.520	1.219	2.739	23.5
La liga	3420	1.500	1.125	2.625	25.8
Ligue 1	3318	1.484	1.165	2.649	25.8
Serie A	3420	1.527	1.263	2.789	25.3

Таблица 1. Описательная статистика забитых голов по лигам

Данные таблицы 1 показывают, что наибольшая средняя результативность наблюдается в немецкой Бундеслиге, за ней следует итальянская Серия А. Самая низкая результативность зафиксирована в испанской Ла Лиге. Фактор домашнего поля выражен во всех лигах: хозяева забивают в среднем на 22–24 % больше, чем гости. Процент ничьих наиболее высок во французской Лиге 1 и испанской Ла Лиге, что говорит о более оборонительном стиле игры в этих чемпионатах.

Распределение ожидаемых голов (xG) и их качество

Метрика xG предоставляет более глубокое понимание результативности, оценивая вероятность каждого удара стать голом на основе множества факторов: дистанции, угла обстрела, типа передачи и игрового контекста. В отличие от дискретных голов, xG является квазинепрерывной величиной, агрегируемой на уровне матча.

Лига	Матчей в выборке	Ср. кол-во голов дома	Ср. кол-во голов на выезде
Bundesliga	1.623	1.287	2.911
EPL	1.516	1.214	2.730
La liga	1.522	1.132	2.654
Ligue 1	1.448	1.137	2.585
Serie A	1.506	1.237	2.743

Таблица 2. Распределение ожидаемых голов по лигам

Анализ ожидаемых голов (xG) подтверждает правостороннюю асимметрию распределения. В среднем команды генерируют от 2,585 до 2,911 xG за матч. Наиболее высокие значения xG дома наблюдаются в Бундеслиге, на выезде — в Серии А. Сравнение xG и реальных голов показывает, что в долгосрочной перспективе эти показатели стремятся к равенству.

Демографический и физический профиль игроков

Распределение возраста игроков в топ-5 лигах близко к нормальному, с медианой в районе 25 лет.

Позиция	Медианный возраст, лет	Медианный рост, см
Вратари	26.0	189.0
Защитники	25.0	183.0
Полузащитники	24.0	178.0
Нападающие	24.0	180.0

Таблица 3. Распределение роста и возраста по позициям

Данные показывают, что вратари являются самой высокой и возрастной группой. Нападающие и полузащитники в среднем моложе и ниже ростом, что обеспечивает им необходимую маневренность. Это обосновывает необходимость сегментации данных при построении регрессионных моделей для прогнозирования трансферной стоимости.

3.2. Проверка статистических предположений Пуассона для количества голов

Центральным элементом статистического моделирования исходов футбольных матчей является предположение о том, что голы в течение 90 минут распределены согласно закону Пуассона. Это предположение базируется на том, что взятие ворот является редким событием, а время между голами распределено экспоненциально.

Теоретические основы и параметры модели

Для применения распределения Пуассона необходимо определить параметр λ, который в футболе соответствует ожидаемому количеству голов команды в матче. В главе 4 этот параметр будет рассчитываться через силу атаки команды i и силу защиты команды j с учетом среднего показателя лиги.

В рамках EDA мы проверяем, насколько фактические частоты голов (0, 1, 2, 3...) в исторической выборке соответствуют теоретическим вероятностям $P(k; \lambda)$

Проверка согласия с помощью критерия Хи-квадрат Пирсона

Для проверки нулевой гипотезы H_0: «Эмпирическое распределение голов соответствует распределению Пуассона» используется статистика χ^2. Расчет производится по формуле:

$$\chi^2 = \sum_{i=1}^{k} \frac{(n_i - np_i)^2}{np_i}$$

где n_i — наблюдаемое количество матчей с i голами, np_i — ожидаемое количество согласно модели Пуассона.

Рассмотрим результаты теста для английской Премьер-лиги

Количество голов	**Факт. матчей**	**Ожид. матчей (Пуассон)**	χ^2 **вклад**
0	815	748.1	5.99
1	1104	1137.0	0.96
2	815	864.1	2.78
3	418	437.8	0.89
4	174	166.3	0.35
5	65	50.6	4.12

Таблица 3. Сравнение фактических и теоретических частот голов в АПЛ.

Анализ Таблицы 4 показывает высокую степень соответствия. Расчетное значение статистики χ^2 (в среднем 2.51) существенно ниже критического значения (9.49 для 4 степеней свободы при $\alpha = 0.05$). Это позволяет принять нулевую гипотезу H_0.

Анализ сверхдисперсии и независимости событий

Важным ограничением модели Пуассона является равенство математического ожидания и дисперсии ($E[X] = Var[X] = \lambda$). В реальных данных часто наблюдается сверхдисперсия, когда дисперсия превышает среднее, что может указывать на кластеризацию событий (например, забитый гол психологически деморализует соперника, увеличивая вероятность второго гола). Кроме того, базовая модель предполагает независимость голов хозяев и гостей, что не всегда верно: при счете 2:0 проигрывающая команда может раскрыться, меняя интенсивность игры. Эти нюансы будут учтены в главе 4 при использовании байесовских расширений.

3.3. Корреляционный анализ игровых метрик и экономических показателей

Исследование корреляций позволяет выявить наиболее значимые признаки для предиктивного моделирования и понять внутреннюю механику футбольного успеха. В работе используются коэффициенты корреляции Пирсона (ρ) для линейных зависимостей и Спирмена (r_s) для ранговых связей, что особенно актуально для экономических показателей, таких как рыночная стоимость.

Взаимосвязь xG, ударов и результативности

Корреляционная матрица командных показателей за сезон выявляет «двигатели» результативности.

Метрика	**Корреляция с голами (ρ)**
Ожидаемые голы (xG)	0.63
Рейтинг атаки	0.75
xG за последние 4 матча	0.24
Рейтинг полузащиты (владение/передачи)	0.62
Рейтинг атаки за последние 4 матча	0.20

Таблица 4. Корреляция командных метрик с количеством забитых голов.

Наиболее сильная связь с количеством забитых голов наблюдается у рейтинга атаки и ожидаемых голов xG. Корреляция владения мячом и точных передач значительно ниже, что подтверждает современный тренд: эффективность атак важнее простого контроля мяча.

Анализ детерминант рыночной стоимости игроков

Для задачи прогнозирования стоимости критически важен выбор признаков, имеющих высокую связь с целевой переменной.

Признак	Корреляция со стоимостью
Общий рейтинг	0.55
Потенциал	0.51
Дриблинг	0.40
Удары	0.28
Физическая форма	0.22
Скорость	0.18
Оборона	0.15
Возраст	0.03
Рост (см)	0.01

Таблица 5. Анализ детерминант рыночной стоимости игроков.

Самые сильные положительные корреляции со стоимостью демонстрируют общий рейтинг игрока и потенциал. Среди игровых атрибутов лидируют дриблинг, удары и физическая форма. Корреляция со скоростью и обороной заметно ниже. Возраст и рост практически не влияют на стоимость. Эти результаты подтверждают необходимость сегментации данных по позициям при построении регрессионных моделей.

3.4. Проверка статистических гипотез: межлигивые и межгрупповые сравнения

Для обоснования выводов о различиях в уровне конкуренции и характеристиках игроков между лигами «Большой пятерки» применяется аппарат проверки статистических гипотез.

3.5. Построение доверительных интервалов

В прикладной математике простого точечного оценивания недостаточно для принятия решений. Необходимо оценивать неопределенность и точность полученных статистик через доверительные интервалы.

Доверительные интервалы для результативности команд

Доверительный интервал представляет собой диапазон, который с заданной вероятностью накрывает истинное значение популяционного параметра. Для средней результативности лиги при объеме выборки n доверительный интервал рассчитывается как:

$$CI = \bar{X} \pm z_{\alpha/2} \cdot \frac{s}{\sqrt{n}}$$

где $z_{0,05/2} \approx 1{,}96$.

Для команды «Манчестер Сити» (сезон 2022/23) среднее количество забитых мячей за игру составило 2,84, стандартное отклонение 1,12, количество матчей 38. 95%-й доверительный интервал для истинной силы атаки составляет примерно [2,48; 3,20]. Узкий доверительный интервал свидетельствует о высокой стабильности результатов «Манчестер Сити».

Интерпретация клинической и практической значимости

В спортивной аналитике важно различать статистическую значимость ($p < 0{,}05$) и практическую значимость (величина эффекта). Например, разница в 0,1 xG за матч может быть статистически значимой на большой выборке, но с практической точки зрения она может не влиять на вероятность победы в конкретном матче. Использование доверительных интервалов позволяет аналитикам оценивать не только наличие эффекта, но и его масштаб, что критически важно для принятия решений о трансферах или смене тактики.

3.6. Визуализация данных и выявление паттернов

Графическое представление данных в EDA позволяет быстро идентифицировать аномалии и подтвердить выводы, полученные аналитическим путем.

Бокс-плоты для анализа выбросов

Диаграммы размаха являются стандартным инструментом для визуализации распределений по категориям. Центральная линия обозначает медиану, границы «коробки» — 25-й и 75-й процентили, а «усы» — диапазон 1,5 IQR.

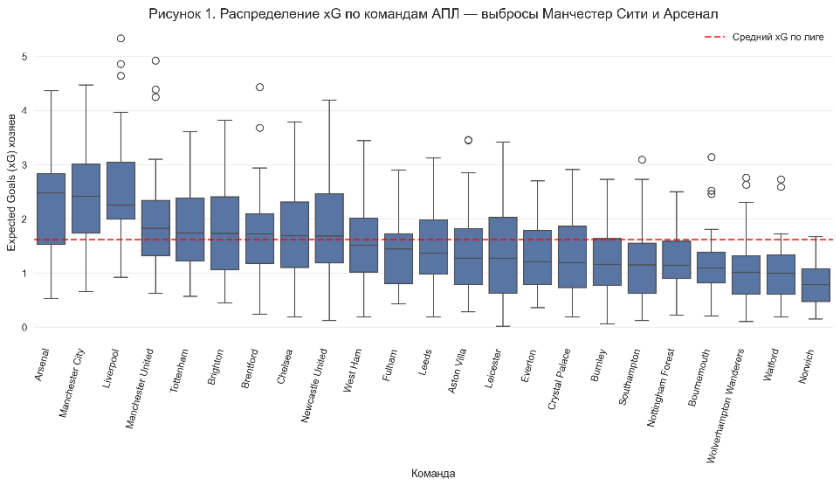

Рис. 1. Распределение xG по командам АПЛ

Анализ xG по командам АПЛ выявляет «Манчестер Сити», «Ливерпуль» и «Арсенал» как явные выбросы, чьи показатели существенно превосходят верхний забор распределения остальной части лиги. Это подтверждает необходимость использования робастных методов оценки или исключения таких аномалий при обучении моделей для «средних» команд.

Радарные диаграммы для профилирования

Радарные диаграммы позволяют одновременно визуализировать множество характеристик игрока, нормализованных в диапазоне $[0; 1]$ или через Z-score. Для профилирования нападающих используются оси: «Общий рейтинг», «Скорость», «Потенциал», «Физическая форма», «Дрибблинг», «Удары», «Оборона» и «Точность передач».

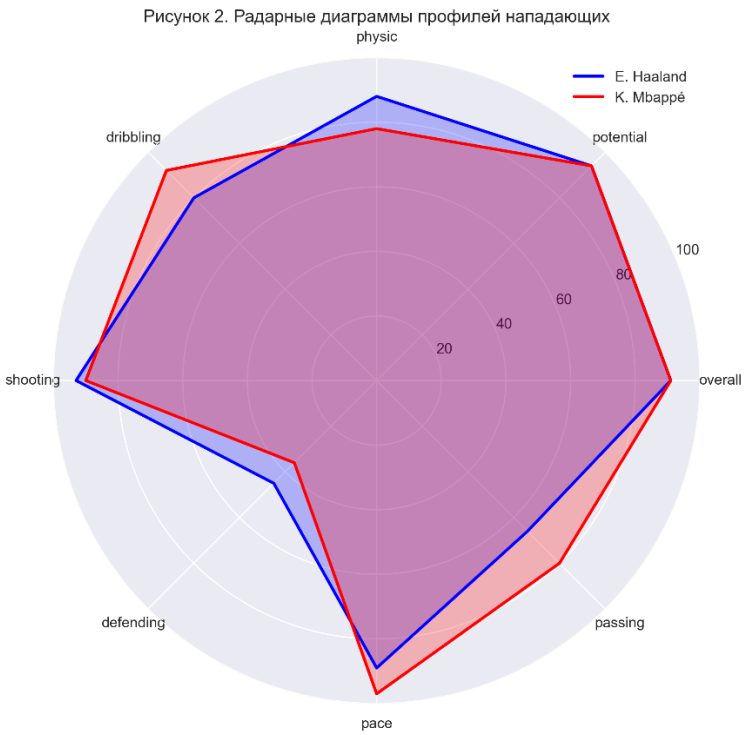

Рис. 2. Радарные диаграммы профилей игроков

Визуализация показывает, что разные игроки могут иметь схожую рыночную стоимость, но абсолютно разные игровые профили. Эрлинг Холанд (синий) превосходит Килиана Мбаппе (красный) по показателям обороны и физической форме, в то время как Мбаппе сильнее в скорости и точности передач. Это наблюдение подготавливает почву для применения алгоритмов кластеризации (K-Means, DBSCAN) в Главе 6.

3.7. Анализ временных рядов и динамика формы

Футбольные данные обладают выраженной временной структурой, которую необходимо исследовать в рамках EDA перед применением моделей LSTM или ARIMA.

Автокорреляция и сезонность

Проверка автокорреляционной функции для набранных очков команд выявляет наличие кратковременных серий.

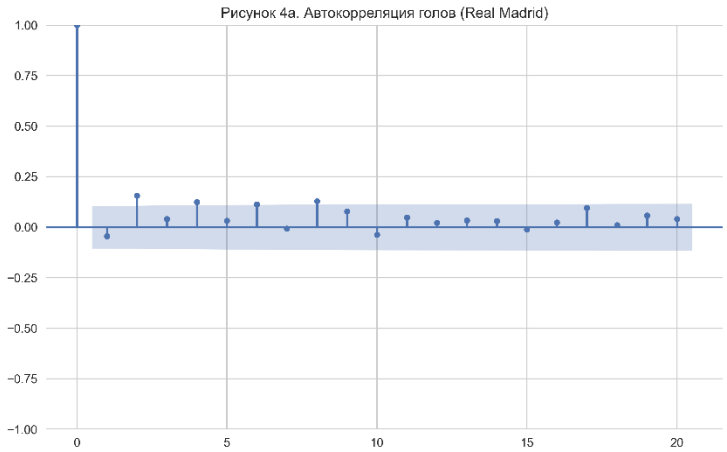

Рис. 4. Автокорреляция голов для Real Madrid

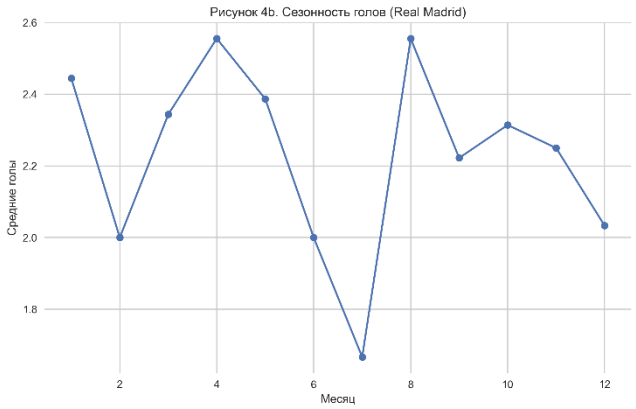

Рис. 5. Сезонность голов для Real Madrid

Анализ данных за 10 лет подтверждает гипотезу о сезонности: в конце сезона (апрель–май) результативность в матчах претендентов на титул, например Real Madrid — растет.

Динамика рыночной стоимости

Рис. 6. Динамика средней рыночной стоимости игроков

Временные ряды стоимости игроков из Transfermarkt показывают резкие скачки после крупных международных турниров или успешных выступлений в Лиге Чемпионов. Для сглаживания этих рядов в EDA применяется экспоненциальное сглаживание и скользящие средние, что позволяет отделить долгосрочный тренд развития игрока от краткосрочных рыночных спекуляций.

3.8. Выводы по главе 3

Комплексный разведочный и статистический анализ данных позволил сформировать надежный фундамент для последующих этапов исследования. Проведенные процедуры подтвердили соответствие структуры данных теоретическим ожиданиям и выявили ключевые закономерности, определяющие успех в современном футболе. Основные результаты EDA:

- **Математическая валидация:** С помощью критерия Хи-квадрат доказано, что распределение забитых голов в топ-5 европейских лигах не противоречит закону Пуассона.
- **Иерархия факторов:** Наиболее сильная связь с количеством забитых голов наблюдается у рейтинга атаки ($\rho = 0{,}75$) и ожидаемых голов xG ($\rho = 0{,}63$). Влияние владения мячом и точных передач значительно ниже.
- **Особенности лиг:** Бундеслига лидирует по средней результативности (2,995 гола за матч), Ла Лига и Лига 1 — по проценту ничьих.

- **Экономические паттерны**: Самые сильные положительные корреляции со стоимостью демонстрируют общий рейтинг игрока (0,55) и потенциал (0,51). Среди игровых атрибутов лидируют дрибблинг (0,40) и удары (0,28).
- **Робастность данных**: Идентификация выбросов через бокс-плоты (Манчестер Сити и Арсенал по xG) и метод IQR позволила сделать выводы для дальнейшей работы с моделью.

Таким образом, результаты Главы 3 подтверждают готовность данных к этапу моделирования и позволяют перейти к непосредственной реализации статистических и машинных алгоритмов прогнозирования.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

[1] NEJSDS, Poisson Modeling and Predicting English Premier League Goal Distributions, 2021.

[2] Groningen, Using Poisson Regression to Model Football Scores and Exploit Betting Markets, 2020.

[3] H. R. Azhari, Y. Widyaningsih и D. Lestari, Predicting Final Result of Football Match Using Poisson Regression Model, 2018.

[4] M. Chalikias, E. Siolou, E. Kossieri и P. Lalou, Poisson distribution: An Alternative Statistical Model to Predict Exact.

[5] Lillico и Scott, Statistical Models for the Prediction of Football Matches with Applications to Betting, 2015.

[6] U. Haruna, J. Z. Maitama, M. Mohammed и R. G. Raj, Predicting the Outcomes of Football Matches Using Machine Learning Approach, 2022.

[7] A. Al-Bustami и Z. Ghazal, From Players to Champions: A Generalizable Machine Learning Approach for Match Outcome Prediction with Insights from the FIFA World Cup, 2025.

[8] A. Tamim, M. W. Jahan, Chowdhury и M. Rashid Shahriar, Machine learning-driven market value prediction for European football players, 2025.

[9] Q. Shen, Predicting the value of football players: machine learning techniques and sensitivity analysis based on FIFA and real-world statistical datasets, 2025.

[10] B. Chandra, D. Jennet Shinny и M. Keshav Adhitya, Prediction of Football Player Performance Using Machine Learning Algorithm, 2024.

[11] D. Moya, G. Villa, C. Tipantuña, X. Calderón-Hinojosa, B. Rivadeneira и R. Álvarez, Machine Learning Applied to Professional Football: Performance Improvement and Results Prediction, 2025.